

Bertrand LECOEUR MMF, Charlotte DROIN MMF, Corentin STEPHAN ACTU


Rapport
Grand Risque et Valeurs Extrêmes



I/ Série X

1. Analyse exploratoire de la série


La série X correspond à des pertes observées à une fréquence mensuelle sur une longue période. La figure ci-dessus présente l'évolution temporelle de ces pertes.




La série présente une forte variabilité ainsi que des pics ponctuels de grande amplitude. Ces observations indiquent la présence d'événements extrêmes rares mais sévères. Les statistiques descriptives de la série sont une moyenne de 17 992,6 et un écart-type de 13 720,8. La dispersion élevée par rapport à la moyenne suggère une distribution fortement asymétrique.

2. Étude de la normalité

La Figure 2 présente l'histogramme de la série X ainsi que la densité d'une loi normale ajustée à partir de la moyenne et de l'écart-type empiriques.



La distribution empirique est clairement asymétrique à droite, avec une queue longue que la loi normale ne parvient pas à reproduire. Cette inadéquation est confirmée par les diagnostics graphiques suivants :




Le QQ-plot par rapport à la loi normale montre que les points s'écartent fortement de la droite de référence dans les quantiles supérieurs, traduisant une probabilité de pertes extrêmes beaucoup plus élevée que celle prédite par la loi normale.

De plus, la comparaison des densités empirique et normale montre que la densité normale sous-estime fortement la masse de probabilité dans la queue droite.

Le quantile 99,5 % estimé sous l'hypothèse de normalité est de 53 335, ce qui apparaît largement insuffisant au regard des observations extrêmes.

3. Modélisation par la loi GEV (maxima annuels par bloc)

Afin de modéliser les pertes extrêmes, une approche par la loi des valeurs extrêmes est mise en œuvre à partir des maxima annuels de la série X. Les diagnostics graphiques associés (probability plot, quantile plot, return level plot et density plot) sont présentés ci-dessous.



On observe dans le probability plot que les points s'écartent systématiquement de la diagonale, et que le modèle sous-estime les probabilités élevées.

Ensuite pour le quantile plot, Pour les grands quantiles, les points empiriques sont nettement sous la droite. Le modèle prédit des pertes beaucoup trop élevées par rapport aux données observées. Enfin, quelques points extrêmes dominent l'ajustement.

Puis le return level plot montre que dès 100-200 ans, les pertes prédites deviennent très élevées.

Enfin, pour le density plot, la densité est raisonnable sur le cœur de la distribution, la queue droite est trop étalée, et le modèle attribue trop de masse aux pertes extrêmes.

Les diagnostics graphiques de la loi GEV mettent en évidence une mauvaise calibration de la queue de distribution. Le modèle tend à surestimer fortement les pertes extrêmes et présente une forte instabilité pour les niveaux de retour élevés.

Afin de mieux modéliser les événements extrêmes, une approche par la théorie des valeurs extrêmes est mise en œuvre. Les maxima annuels de la série X sont extraits et ajustés à une loi GEV.

Les paramètres estimés de la loi GEV sont un paramètre de position (location) de 38 472,8, un paramètre d'échelle (scale) de 18 074,6 et enfin un paramètre de forme (shape) de 0,6514.


Le quantile 99,5 % issu du modèle GEV est de 884 401. Cette valeur est extrêmement élevée car elle est en année et non en mois. Les graphiques de diagnostic GEV (probability plot, quantile plot, return level plot) montrent que l'ajustement est fortement influencé par les observations les plus extrêmes, ce qui rend ce modèle instable pour l'estimation de quantiles de risque opérationnel.

4. Modélisation par la loi GPD (méthode POT)


Une approche Peaks Over Threshold (POT) est ensuite utilisée afin de modéliser uniquement les excès au-delà d'un seuil élevé u .

4.1 Choix du seuil


Le choix du seuil repose sur plusieurs diagnostics. La stabilité du paramètre de forme $\xi(u)$, la stabilité du paramètre d'échelle $\beta(u)$, le nombre d'excès au-dessus du seuil ainsi que du Mean Excess Plot.



Le paramètre de forme ξ est très instable pour des seuils faibles, ce qui traduit une mauvaise séparation entre le corps et la queue de la distribution. À partir d'un seuil autour du quantile 90 % ($\approx 30\,000$), ξ devient relativement stable.




Le paramètre d'échelle β augmente fortement pour des seuils faibles, puis se stabilise autour du quantile 90 %, indiquant une zone d'estimation fiable. Au-delà, la hausse de β reflète la raréfaction des excès et une augmentation de l'incertitude.



Le nombre d'excès décroît rapidement lorsque le seuil augmente, traduisant le compromis classique biais–variance. Autour du quantile 90 %, le nombre d'excès reste suffisant pour garantir une estimation fiable tout en se concentrant sur la queue de distribution.

Ainsi, les graphes de stabilité montrent qu'à partir du quantile 90 %, les paramètres deviennent relativement stables tout en conservant un nombre suffisant d'excès. Le Mean Excess Plot confirme une relation approximativement linéaire au-delà de ce seuil, comme le montre la figure ci-dessous :



Le seuil retenu est donc 30 108.

4.2 Estimation des paramètres GPD

Les paramètres estimés de la loi GPD sont un paramètre d'échelle $\beta=10\,897$ et un paramètre de forme $\xi=0,2833$

La valeur positive du paramètre ξ confirme la présence d'une queue lourde, mais de manière beaucoup plus modérée et stable que dans le cas du modèle GEV.

Le quantile 99,5 % estimé par la GPD est 81605.

Cette estimation est cohérente avec l'historique observé et se situe à un niveau intermédiaire entre l'approche empirique et la GEV.

5. Comparaison des modèles pour le quantile 99,5 %

Les différentes estimations du quantile 99,5 % pour la série X sont résumées ci-dessous :

	Modele	Serie_X
1	Empirique	75118.99
2	Normale	53335.10
3	GEV	884400.62
4	GPD	81605.27

La loi normale sous-estime fortement le risque extrême.

La loi GEV produit une estimation excessivement élevée, peu robuste.

La loi GPD offre un compromis pertinent entre prudence et stabilité statistique.

6. Niveau de retour 200 ans

En utilisant le modèle GPD, la perte associée à un niveau de retour de 200 ans (soit 2 400 mois) est estimée à une perte 200 ans de X de 173 529.

Cette valeur constitue une mesure réaliste du risque extrême à long terme pour la série X.

7. Conclusion sur la série X


L'analyse de la série X met en évidence une forte asymétrie, des queues lourdes, et une inadéquation claire de la loi normale. Parmi les modèles testés, l'approche GPD avec seuil au quantile 90 % apparaît comme la plus adaptée pour la modélisation des pertes extrêmes. Elle fournit des estimations de quantiles et de niveaux de retour cohérentes avec les données et suffisamment robustes pour une utilisation en gestion des risques.

II/ Série Y

1. Modélisation par une loi Normale

La série Y est ajustée par une loi Normale, dont les paramètres sont estimés par maximum de vraisemblance. On obtient les valeurs suivantes:

- Moyenne estimée : $\mu_{normale} = 720.33$
- Ecart-type estimé : $\sigma_{normale} = 51.34$



Les graphiques montrent que la loi Normale s'ajuste globalement bien au centre de la distribution. Cependant, le QQ-plot révèle que la loi Normale tend à s'éloigner des données aux extrémités. Les valeurs observées tendent à être en dessous de celles prévues par la loi Normale.

Le quantile à 99.5% estimé par la loi Normale est de 852.57. Comparé au quantile empirique (825.69), la loi Normale surestime le risque pour cette série.

Donc la loi Normale a tendance à surestimer la série Y.


2. Modélisation GEV

La série mensuelle a été agrégée en maxima annuels. Une loi GEV a été ajustée sur ces maxima, fournissant les paramètres suivants :

- Localisation : $\mu_{gev} = 785.04$
- Echelle : $\beta_{gev} = 21.61$
- Shape : $\xi_{gev} = -0.2498$

La valeur négative du paramètre $\xi_{gev} < 0$ indique que la distribution des maxima suit une loi de Weibull caractérisée par une queue bornée supérieurement.

Contrairement à la série X la série Y semble posséder un “plafond théorique” des pertes.



Dans le probability plot, les points suivent assez bien les probabilités théoriques GEV. Les valeurs des maximums observés dans le quantile plot collent aussi assez bien aux prédictions du modèle. Dans le return level plot, la courbe est concave, cela justifie le caractère borné de la queue de la série Y. Enfin, l'histogramme représente la distribution des maximums. La densité GEV s'ajuste de manière correcte.


Donc la GEV capture bien la nature bornée du risque mais l'estimation repose sur un nombre réduit de points maxima annuel, ce qui limite la robustesse de cette méthode.

3. Modélisation GPD et Mean Excess Plot


La méthode Peaks Over Threshold (POT) est appliquée directement à l'ensemble des données mensuelles.

Choix du seuil


Nous nous sommes intéressés aux paramètres scale et beta afin de justifier notre seuil choisi.



Sur la partie gauche, nous observons un plateau stable où le paramètre oscille peu (autour de -0.33). Sur la droite, la volatilité explose.




Nous observons une rupture de structure très nette au-delà du seuil de 790. La volatilité devient incontrôlable (partie droite du graphique).



Vers 782, nous conservons exactement 60 observations (excès). C'est un volume de données suffisant pour garantir la convergence statistique du modèle. Au-delà de ce point, le nombre d'observations chute trop rapidement

Le Mean Excess Plot vient valider le seuil optimal.



Le graphique montre une pente décroissante linéaire.

Sur la base de ce graphique et de la stabilité des paramètres, un seuil de travail $u = 782.64$ (correspondant au quantile 90%) a été retenu. Puis, en gardant 10% des valeurs, il reste environ 60 observations, c'est un choix acceptable pour rester précis. Nous obtenons ces résultats:

GPD - Paramètres : Seuil (u) = 782.64 | Scale (beta) = 23.18 | Shape (xi) = -0.2899
GPD - Quantile 99.5% : 829.09

Donc nous retenons un seuil à 90% pour la loi GPD.

L'ajustement GPD au-dessus de ce seuil donne :

- Echelle : $\beta_{GPD} = 23.18$
- Shape : $\xi_{GPD} = -0.28994$

4. Choix du modèle

Le tableau récapitulatif des quantiles est le suivant:

	Modele	Serie_X	Serie_Y
1	Empirique	75118.99	825.69
2	Normale	53335.10	852.57
3	GEV	884400.62	848.49
4	GPD	81605.27	829.08

On observe que la loi la plus proche du quantiles 99.5% empirique est la loi GPD. Or, la loi GEV a un quantile qui ne peut pas être interprété comme les autres car il est annuel et non mensuel. Le rendre mensuel diminuerait la précision des autres lois car on peut pas s'approcher de 99.5. En effet, en appliquant $^{1/12}$ au quantile annuel de GEV pour le rendre mensuel, cela nous forcerait à transformer les quantiles 99.5% des autres lois en un quantile 99.958%.

Nous avons privilégié l'approche GPD car la méthode GEV souffre d'une perte d'information. En effet, en ne retenant qu'un seul événement par période, la GEV ignore d'autres sinistres majeurs survenus la même année. Ceci réduit la robustesse de l'estimation statistique. De plus, d'un point de vue mathématique, la GPD utilise plus de points que la GEV. Les estimations des paramètres sont généralement plus précises et ont une variance plus faible. C'est le cas par exemple pour la série X où le quantile GEV est démesuré comparé au quantile de la loi GPD. Enfin, la GEV suppose souvent que les maxima sont indépendants d'une période à l'autre. La méthode GPD permet de mieux gérer les événements où il y a plusieurs pics d'affilée.

Nous avons donc fait le choix de retenir la loi GPD.

5. Période de retour 200 ans

A partir de la loi GPD, la perte associée à une période de retour de 200 ans pour la série Y est estimée à 829.09.

Ainsi, concernant la série Y, la loi Normale surestime le risque, la loi GEV utilise moins de données historiques. La loi GPD semble être la loi la plus adaptée car elle modélise

correctement la décroissance rapide du risque extrême (mean excess plot) et utilise plus de données historiques que la GEV.

III/ Copules

1. Transformation en pseudo-observations


Afin d'étudier la dépendance entre les séries de pertes X et Y indépendamment de leurs lois marginales, les données sont transformées en pseudo-observations.

Chaque série est convertie à l'aide de sa fonction de répartition empirique :

$$U=F_X(X), V=F_Y(Y)$$

Cette transformation permet d'obtenir deux variables uniformes sur $[0,1]$, tout en conservant uniquement la structure de dépendance entre les séries.

Le nuage de points des pseudo-observations (U,V) met en évidence une dépendance positive, particulièrement marquée pour les valeurs élevées. Lorsque les pertes de la série X sont importantes, celles de la série Y ont également tendance à l'être, suggérant une dépendance non linéaire et potentiellement asymétrique.




2. Ajustement des copules

Plusieurs familles de copules sont testées afin de modéliser la dépendance entre X et Y :

- Copule d'indépendance

- Copule gaussienne
- Copule de Clayton
- Copule de Frank
- Copule de Gumbel

Les paramètres sont estimés par maximum de vraisemblance. Les modèles sont ensuite comparés à l'aide des critères d'information AIC et BIC, qui évaluent le compromis entre qualité d'ajustement et complexité du modèle.



3. Sélection du modèle par critères AIC et BIC

La comparaison des critères AIC et BIC montre que la copule **Gumbel** présente les valeurs les plus faibles, indiquant la meilleure adéquation aux données parmi les modèles testés.

La copule gaussienne, bien qu'adaptée à des dépendances symétriques, ne parvient pas à capturer correctement le comportement conjoint des pertes extrêmes. Les copules de Clayton et de Frank offrent un ajustement plus limité, tandis que la copule d'indépendance est très largement rejetée.

La copule Gumbel est donc retenue comme modèle final de dépendance entre X et Y.

4. Interprétation de la copule Gumbel

La copule Gumbel est particulièrement adaptée à la modélisation des **dépendances de queue supérieure**. Elle permet de capturer le fait que les pertes extrêmes ont tendance à se produire simultanément.

Concrètement, cela signifie que lorsque la perte de la série X est élevée, la probabilité d'observer simultanément une perte élevée sur la série Y est significativement plus forte que dans un cadre d'indépendance. Cette caractéristique est essentielle dans une perspective de gestion du risque global.

5. Test d'adéquation de la copule

Un test d'adéquation paramétrique de type Kolmogorov–Smirnov est appliqué à la copule Gumbel ajustée.

- Statistique du test : 0.067
- p-value : 0.0005

La faible p-value indique que la dépendance observée est significative et ne peut être attribuée au hasard. Les résultats confirment que la copule Gumbel capture efficacement la structure de dépendance extrême entre les séries X et Y.

6. Simulation conjointe à l'aide de la copule Gumbel

À partir de la copule Gumbel calibrée, un grand nombre de couples (U, V) est simulé par Monte-Carlo. Ces pseudo-observations simulées constituent la base de la génération de pertes conjointes fictives sur une longue période.

Les simulations permettent de représenter des scénarios extrêmes rares, impossibles à observer directement dans les données historiques.

7. Modélisation marginale par lois GPD

Les marges sont modélisées par des lois de Pareto généralisées (GPD), ajustées sur les excès au-dessus de seuils sélectionnés :

- **Série X :**

- Paramètre de forme $\xi > 0$
→ queue lourde, indiquant un potentiel de pertes extrêmes élevées.
- **Série Y :**
 - Paramètre de forme $\xi < 0$
→ queue bornée, impliquant l'existence d'un plafond théorique des pertes.

Cette asymétrie entre les deux séries renforce l'intérêt d'une modélisation conjointe cohérente entre dépendance et marges.

Les pseudo-observations simulées sont ensuite transformées en pertes réelles à l'aide des quantiles GPD correspondants.

8. Agrégation annuelle des pertes combinées

Les pertes mensuelles simulées sont agrégées sous la forme :

$$Z = X + Y$$

On calcul le sinistre mensuel maximal de l'année. Mais il y a aussi une approche, les pertes combinées sont regroupées par année, et le maximum annuel est retenu afin de se placer dans une logique de gestion du risque extrême à horizon annuel.


9. Perte annuelle combinée – période de retour 200 ans

Le quantile à 99,5 % des maxima annuels simulés fournit une estimation de la perte annuelle combinée associée à une période de retour de 200 ans.

$$Z_{200} \approx 181\,397$$

Cette valeur reflète l'impact conjoint :

- de la queue lourde de la série X,
- de la borne supérieure de la série Y,
- et surtout de leur dépendance extrême capturée par la copule Gumbel.



10. Analyse de la dépendance extrême et comparaison avec l'indépendance

Les simulations réalisées sous hypothèse d'indépendance conduisent à des pertes combinées nettement plus faibles. Cela démontre que négliger la dépendance entre X et Y entraîne une **sous-estimation significative du risque global**.

La copule Gumbel met en évidence que les pertes extrêmes ont une forte probabilité de se produire simultanément, amplifiant ainsi le risque total du portefeuille.

11. Robustesse des résultats

- Le nombre élevé de simulations garantit la stabilité des estimations.
- La cohérence entre la modélisation marginale (GPD) et la dépendance (copule Gumbel) renforce la crédibilité des résultats.
- Les conclusions sont robustes aux choix méthodologiques retenus.

IV/ Conclusion général

Ce projet a permis de modéliser les pertes extrêmes des portefeuilles X et Y à l'aide de la Théorie des Valeurs Extrêmes et d'analyser leur dépendance via les copules.

La modélisation GPD s'est révélée la plus adaptée pour les deux séries : la série X présente une queue lourde, tandis que la série Y est caractérisée par une queue bornée.

L'étude de la dépendance montre une dépendance extrême significative entre X et Y, correctement capturée par la copule de Gumbel. Même si d'autres copules auraient pu être utilisées comme la copule de Survie Clayton et Survie Gumbell. La simulation conjointe met en évidence que cette dépendance augmente fortement la perte annuelle combinée à horizon 200 ans.

Ainsi, ignorer la dépendance entre les portefeuilles conduit à une sous-estimation du risque global, ce qui confirme l'importance d'une modélisation conjointe des marges et de la dépendance pour une gestion réaliste des risques extrêmes.